

Robô Trader em Python: Análise de Dados e Modelagem Preditiva para o Mercado Financeiro

Autores: Jean Carlos Barros da Mata (202206120) e
Juliana do Nascimento Rocha (202201645)

1. Introdução

Este artigo apresenta o desenvolvimento de um sistema automatizado de trading (Robô Trader) utilizando Python, como parte da disciplina de Tópicos em Engenharia de Sistemas de Informação 3. O sistema tem como objetivo analisar padrões do mercado financeiro brasileiro, especificamente do mini índice da B3, e tomar decisões de compra e venda de forma automatizada. O projeto integra análise exploratória de dados, feature engineering e modelagem preditiva para otimizar estratégias de trading.

2. Metodologia

2.1 Análise Exploratória dos Dados

Foram analisados dados históricos do mini índice da B3 no período de 15 de outubro de 2020 a 19 de abril de 2023. A análise inicial focou em compreender o comportamento do ativo através de diversas visualizações:


2.1.1 Análise de Tendência

- **Preço e Médias Móveis:** Utilizou-se médias móveis de curto (20 dias) e longo prazo (50 dias) para identificar tendências de mercado
 - Preço acima das médias: indicativo de otimismo do mercado
 - Preço abaixo das médias: indicativo de pessimismo
 - Convergência das linhas: sinal de indecisão no mercado

2.1.2 Análise de Volatilidade

- **Volatilidade Diária:** Medida através da variação entre maior e menor valor diário
 - Períodos com alta volatilidade (final de 2022) indicam maior risco e imprevisibilidade
 - Distribuição temporal mostra maior volatilidade próxima ao fechamento

Figura 1 - Análise exploratória de volatilidade



Fonte: autoria própria

2.1.3 Análise de Volume e Spread

- Volume Transacional (TickVol): Número de negociações por período
- Spread: Diferença entre preços de compra e venda
 - Relação inversa esperada entre volume e spread não foi claramente observada
 - Spread manteve-se constante na maioria dos períodos, sugerindo possível limitação nos dados coletados

2.1.4 Distribuição de Retornos e Volatilidade

- Retornos Diários: Distribuição leptocúrtica com leve assimetria negativa
 - Maior concentração em variações pequenas
 - Risco de perdas grandes e repentinas
 - Tendência ligeiramente positiva de valorização no período analisado
- Padrão Temporal: Maior volume negociado concentrado no horário de abertura

2.2 Construção dos Conjuntos de Dados

Foram desenvolvidos dois conjuntos de dados principais, posteriormente consolidados:

1. Dataset_final_processado: Baseado nas variáveis sugeridas pelo método de Jean
2. Dataset_diarios: Baseado nas variáveis sugeridas pelo método de Juliana

A consolidação ocorreu após análise comparativa através de matrizes de confusão e importância de features, observando-se que:

- O dataset de Jean apresentou melhor desempenho para verdadeiros negativos
- O dataset de Juliana apresentou melhor desempenho para verdadeiros positivos


O dataset_final_processado resultante foi normalizado, gerando o dataset_pronto_para_modelo. Durante validações, a feature media_diaria foi identificada como potencialmente problemática por incorporar informação futura, levando à sua remoção nas simulações finais.

2.3 Estratégia de Modelagem

A abordagem adotada utiliza múltiplos algoritmos de aprendizado de máquina:

1. Regressão Logística: Para classificação binária inicial
2. Random Forest: Para capturar relações não-lineares
3. XGBoost: Para otimização de performance preditiva
4. Support Vector Machines: Para separação de padrões complexos
5. DBSCAN: Sugerido pelo professor para clustering e detecção de anomalia

Figura 2 - Matriz de confusão de Regressão Logística (fechou ou não fechou?)



Fonte: autoria própria

2.4 Redução de Dimensionalidade e Seleção do Modelo Final

Após a construção e validação inicial dos datasets, foram definidas as features utilizadas na modelagem, resultantes do processo de feature engineering aplicado ao comportamento de abertura, volatilidade e padrões de gap do mini índice. As variáveis finais consideradas foram:

- ALVO_FECHOU_GAP_30MIN
- GAP_NA_FAIXA_IDEAL
- DIVERGENCIA_ABERTURA
- GAP_ALTA
- GAP_PORCENTAGEM_norm
- DIAS_DESDE_ULTIMO_GAP_norm
- VOLATILIDADE_ANTERIOR_norm
- FORCA_ABERTURA_10MIN_norm
- TEND_Aumentando
- TEND_Diminuindo
- TEND_Estavel

Apesar de o conjunto possuir apenas 10 dimensões, o professor recomendou aplicar técnicas de redução de dimensionalidade para verificar possíveis ganhos de desempenho, simplicidade e generalização do modelo. Três métodos foram testados:

- PCA (Principal Component Analysis)
- LDA (Linear Discriminant Analysis)
- LLE (Locally Linear Embedding)


Entre essas técnicas, o PCA apresentou os melhores resultados, como é possível ver na figura 3, preservando maior variância explicada e mantendo boa separabilidade entre as classes. A dimensionalidade foi reduzida para 5 componentes principais, cada um representando uma combinação ponderada das features originais, como é possível ver na figura 4.

Figura 3 - Comparação entre PCA, LLE e LDA



Fonte: autoria própria

Figura 4 - Composição de features com as 5 dimensões



Fonte: autoria própria


2.5 Avaliação dos Modelos com Dimensões Reduzidas

Com o novo dataset reduzido pelo PCA, foram testados quatro algoritmos:

- Random Forest
- KMeans
- Regressão Logística
- DBSCAN

Assim como nos experimentos anteriores, o Random Forest apresentou o melhor desempenho geral, mesmo após a transformação das features. O modelo mostrou-se robusto a ruídos, comportamentos não-lineares e distribuições complexas após a redução de dimensionalidade

Figura 5 - Matriz de confusão Random Forest depois da redução de dimensões



Fonte: autoria própria

Essa consistência motivou sua escolha como modelo preditivo principal do simulador de trading.

3. Desenvolvimento do Simulador de Trading


Com base nos resultados obtidos, o sistema automatizado foi implementado utilizando o Random Forest treinado sobre os dados reduzidos por PCA, integrando:

- Processamento e preparação dos dados de mercado em tempo real
- Aplicação do modelo preditivo para classificação dos cenários de abertura
- Tomada de decisão automatizada de compra ou venda
- Registro e monitoramento dos resultados simulados

Durante a etapa de simulação, o modelo demonstrou bom desempenho, apresentando poucas perdas e um ganho acumulado consistente, mesmo operando com baixa frequência — aproximadamente uma operação a cada quatro dias. Isso reforça o caráter conservador e seletivo da estratégia.


Para avaliar a robustez das previsões, foi aplicada a técnica de Walk Forward Analysis, que permite verificar o desempenho do sistema em janelas temporais sequenciais, simulando sua aplicação no mundo real. Durante essa validação, identificou-se que o simulador estava utilizando constantes que influenciavam artificialmente o ganho esperado, como mostra a figura 6. Após detectar e corrigir essa inconsistência, o desempenho permaneceu positivo e estável, porém com valores mais realistas e condizentes com o comportamento histórico do ativo, como mostra a figura 7.

Figura 6 - Resultados do primeiro simulador



Fonte: autoria própria


Figura 7 - Resultados do segundo simulador



Fonte: autoria própria

Por fim, foi analisado o impacto da confiança mínima necessária para que o modelo executasse uma operação. Foram comparadas simulações com limiares de 50% e 55%, sendo que a confiança de 55% apresentou melhor resultado, oferecendo maior segurança e reduzindo sinais ruidosos sem comprometer a frequência operacional.

Figura 8 - Comparação entre os intervalos de confiança



Fonte: autoria própria

4. Conclusão

O desenvolvimento do Robô Trader em Python permitiu integrar análise exploratória, engenharia de atributos, técnicas de redução de dimensionalidade e modelos preditivos aplicados ao mercado financeiro brasileiro. A partir da análise detalhada do mini índice da B3, foi possível construir um conjunto de features relevantes, identificar padrões de comportamento de abertura e desenvolver um sistema automatizado capaz de operar de forma consistente e baseada em dados.

Os experimentos realizados demonstraram que o Random Forest foi o modelo mais eficiente, tanto antes quanto após a redução dimensional via PCA, apresentando robustez frente a relações não-lineares e diferentes combinações de variáveis. A aplicação de técnicas como Walk Forward Analysis fortaleceu a confiabilidade do simulador ao avaliar seu desempenho em condições próximas das reais, revelando a necessidade de ajustes e garantindo maior integridade nos resultados.

O simulador final apresentou poucas perdas, um ganho acumulado satisfatório e comportamento operacional conservador, realizando em média uma operação a cada quatro dias. Além disso, a análise do limiar de confiança indicou que 55% foi a configuração mais eficaz, reduzindo operações com baixo respaldo preditivo sem comprometer a lucratividade.

Em síntese, o projeto confirma a viabilidade de empregar métodos de machine learning para apoio à tomada de decisão no mercado financeiro, ressaltando a importância de uma abordagem cuidadosa envolvendo preparação de dados, validação rigorosa e avaliação prática. Como trabalhos futuros, sugere-se explorar modelos mais avançados, como redes neurais recorrentes e transformers, ampliar o número de ativos avaliados e incorporar custos operacionais reais para uma simulação mais completa.